UNIVERSIDAD DE GUADALAJARA
Centro Universitario de Guadalajara (CUGDL)
Licenciatura en Inteligencia Artificial y Ciencia de Datos
Proyecto integrador · Tercer semestre

POWERSHIFT AI

Orquestador Invisible de Energía y Costos

Reporte de Machine Learning e Inferencia Bayesiana
y de Matemáticas Aplicadas a la Ciencia de Datos

ASIGNATURAS

Machine Learning e Inferencia Bayesiana
Matemáticas Aplicadas a la Ciencia de Datos
Profesor: **Ivan Alejandro Toledano Juarez**

INTEGRANTES DEL EQUIPO

Gabriel Orozco Alvárez
Yohann Emmanuel Bustos Peñaloza
Angel Zoe García Granados
Juan Pablo Arroyo León

Fecha de entrega: **17 de noviembre de 2026**
Repositorio: https://github.com/22Freetwo/PowerShift-AI-Orquestador-Energia

Resumen

Una regresión logística predice, con la información del día anterior, en qué horas va a estar cargando el vehículo eléctrico (EV) de una vivienda real, con AUC de 0.852 y una precisión promedio 3.2 veces mayor que la del azar. Se comparan seis clasificadores, dos de ellos bayesianos, sobre datos horarios de Open Power System Data con partición cronológica, y se desarrolla la matemática de tres modelos. La hora del día explica casi toda la señal; los seis modelos quedan muy cerca entre sí. El análisis también muestra que el 83 % de la energía del EV se carga entre las 10:00 y las 17:00 h, lo que contradice la ventana nocturna que supone el optimizador del proyecto. En simulación, una ventana de carga aprendida del hábito logra prácticamente el mismo ahorro que la nocturna (alrededor de 54 % del costo del EV).

1. Introducción y planteamiento del problema

1.1 Problemática

PowerShift AI es un orquestador pensado para un dispositivo Edge (Raspberry Pi) que mueve las cargas pesadas del hogar a las horas de menor Precio Marginal Local (PML). En el perfil del sistema SIN que usamos [2], el PML va de 347.46 MXN/MWh a las 10:00 h a 2,210.92 MXN/MWh a las 19:00 h: la misma energía cuesta 6.4 veces más según la hora. Para mover la carga del EV, el optimizador necesita saber en qué horas es probable que el auto esté cargando.

1.2 Objetivo

Estimar, al cierre de cada día, la probabilidad de que el EV esté cargando en cada una de las 24 horas del día siguiente, de forma análoga al Mercado del Día en Adelanto. Además, comparar modelos y elegir uno que sea preciso, que dé probabilidades útiles y que sea ligero para el Edge.

1.3 Justificación

El optimizador del proyecto supone que el auto solo se puede cargar de 18:00 a 08:00 h, pero en los datos reales solo el 7.2 % de la energía del EV se carga en ese horario y el 83.0 % se carga entre las 10:00 y las 17:00 h. Una probabilidad aprendida de los hábitos de la casa puede sustituir ese supuesto fijo.

2. Descripción de los datos

2.1 Fuentes

La fuente principal es Open Power System Data (OPSD), *Household Data* [1][3]: lecturas cada 15 min de la vivienda `DE_KN_residential4` de Konstanz, Alemania, la única del conjunto que mide a la vez bomba de calor, cargador de EV y consumo de red. El notebook 00 la convierte en un archivo horario (`datos_horarios.csv`) con 506 días completos (14 oct 2015 – 5 mar 2017) y 12,144 horas sin valores faltantes. El PML del SIN (CENACE, Mercado del Día en Adelanto) [2] es un perfil de 24 valores y se usa como contexto del problema, no como variable del modelo.

2.2 Variables

La variable objetivo indica si el EV está cargando en la hora. Las 8 variables explicativas solo usan lo que se sabe al terminar el día anterior.

Tabla 1. Variable objetivo y variables explicativas.

Variable	Tipo	Qué mide
y (objetivo)	Binaria	1 si la potencia media del EV en la hora es mayor que 0.1 kW
`hora`	Categórica (0–23)	Hora del día
`dia_semana`	Categórica (0 = lunes … 6 = domingo)	Día de la semana
`carga_ayer_hora`	Binaria	Si cargó a esa misma hora el día anterior
`carga_semana_hora`	Binaria	Si cargó a esa hora hace 7 días
`frec_hora_28d`	Continua (0–1)	Fracción de los últimos 28 días con carga a esa hora
`ev_ayer_kwh`	Continua (kWh)	Energía que cargó el EV el día anterior
`horas_carga_7d`	Discreta	Horas con carga en los 7 días anteriores
`dias_sin_cargar`	Discreta (1–7)	Días desde el último día con carga (≥ 0.5 kWh)

2.3 Tipo de problema

Clasificación binaria con clases desbalanceadas: el EV carga en el 9.4 % de las horas, así que acertar siempre “no carga” daría 90.6 % de exactitud sin servir de nada. Por eso se miden métricas de ranking y de calidad de la probabilidad.

3. Limpieza y preparación de datos

- **Origen limpio.** OPSD entrega lecturas acumuladas de medidor; el notebook 00 las convierte a kW, pasa a hora local (Europe/Berlin), interpola huecos de hasta 1 h y descarta 5 días: 3 por cambio de horario y 2 parciales en los extremos de la ventana. El archivo horario no tiene valores faltantes.
- **Umbral del objetivo.** El 81.0 % de las horas el EV marca 0 kW y el 9.6 % marca entre 0 y 0.1 kW, pero esas horas suman solo 0.37 % de su energía (espera o final de carga). Por eso y = 1 cuando la potencia supera 0.1 kW. El resultado casi no depende del umbral: 9.73 % de horas positivas con 0.05 kW y 8.91 % con 0.2 kW.
- **Faltantes por rezagos.** Las variables de rezago necesitan historia (28 días para `frec_hora_28d`, con al menos 21 disponibles). Se descartaron 25 días sin historia completa; quedan 481 días y 11,544 horas.
- **Variables categóricas.** One-hot para la regresión logística (la relación con la hora no es lineal), seno y coseno para KNN (las 23 h quedan cerca de las 0 h) y enteros para los árboles y el modelo Beta-Binomial.
- **Escalado.** Las continuas se estandarizan para la regresión logística y KNN, y se discretizan en cuantiles para Naive Bayes. Escaladores y cortes se ajustan solo con el entrenamiento.
- **Valores atípicos.** No se quitaron: la potencia del EV está acotada (máximo 3.16 kW por hora) y el objetivo es binario.
- **División temporal.** Entrenamiento: 5 nov 2015 – 13 oct 2016 (341 días, 8,184 horas, 8.44 % positivas). Prueba: 14 oct 2016 – 5 mar 2017 (140 días, 3,360 horas, 11.93 % positivas). Una división al azar

mezclaría horas del mismo día en ambos lados e inflaría las métricas. Los hiperparámetros se eligen con validación cruzada temporal: el entrenamiento se parte en 5 bloques de días consecutivos y cada pliegue entrena con los bloques anteriores y valida con el siguiente (4 pliegues).

4. Análisis exploratorio

Todo el análisis usa solo el año de entrenamiento. Las variables numéricas tienen estos valores:

Tabla 2. Estadísticas descriptivas de las variables numéricas (entrenamiento).

Variable	Media	Desv. est.	Mínimo	Mediana	Máximo
`frec_hora_28d`	0.09	0.12	0.00	0.04	0.56
`ev_ayer_kwh` (kWh)	2.64	3.28	0.00	0.81	14.36
`horas_carga_7d`	14.27	6.05	0	14	33
`dias_sin_cargar`	2.04	1.46	1	1	7

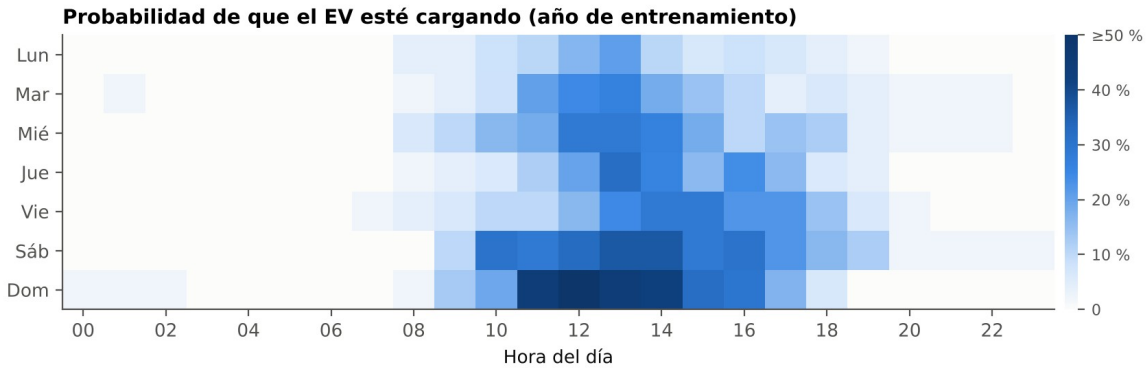


Figura 1. Fracción de horas con el EV cargando, por día de la semana y hora (año de entrenamiento).

- **Hora.** La probabilidad máxima es a las 13:00 h (30.5 %); entre las 21:00 y las 07:00 h es casi cero. El 83.0 % de la energía del EV se carga entre las 10:00 y las 17:00 h, un patrón compatible con carga en horas de sol; este análisis no usa la columna de generación solar (`pv`) que sí trae OPSD para esta vivienda, así que no podemos confirmar el motivo.
- **Día.** Va de 4.3 % de las horas el lunes a 12.2 % el sábado y 12.9 % el domingo.
- **Persistencia.** Si el EV cargó a esa hora el día anterior, la probabilidad sube de 7.1 % a 23.0 %; si cargó hace una semana, de 7.3 % a 20.6 %.
- **Variables diarias.** La correlación de Spearman con el objetivo es 0.33 para `frec_hora_28d`, pero casi cero para `ev_ayer_kwh` (0.003), `horas_carga_7d` (0.005) y `dias_sin_cargar` (−0.010): lo que pasó el día anterior en total dice poco sobre una hora concreta.
- **Cambio de nivel.** El EV carga en el 8.4 % de las horas de entrenamiento y en el 11.9 % de las de prueba; un modelo entrenado con el primer año tenderá a subestimar la carga del invierno 2016–2017.

5. Modelado de Machine Learning

Se entrenaron seis clasificadores. Cada uno eligió sus hiperparámetros con la validación cruzada temporal, maximizando la precisión promedio (AP).

Tabla 3. Modelos evaluados.

Modelo	Cómo funciona	Por qué se usa	Hiperparámetros elegidos
Bayes por hora y día (Beta-Binomial)	Para cada combinación hora × día estima la probabilidad de carga con una distribución Beta a posteriori	Es el modelo bayesiano más simple y sirve de línea base: solo usa el hábito	Fuerza del prior 0.05 (la AP casi no cambia en la malla: 0.254 a 0.255)
Regresión logística	Modelo lineal en el logaritmo de los momios, con regularización L2	Entrega probabilidades directamente y coeficientes interpretables	C = 10
Naive Bayes categórico	Aplica el teorema de Bayes suponiendo variables independientes dada la clase	Es el clasificador bayesiano del curso y se entrena contando	2 intervalos por variable continua, α = 0.0001
Árbol de decisión	Parte los datos con reglas del tipo “hora entre 10 y 16”	Es fácil de explicar y capta interacciones	Profundidad máxima 4, mínimo 50 horas por hoja
Random Forest	Promedia 300 árboles entrenados con muestras y variables al azar	Reduce la varianza de un solo árbol	Profundidad máxima 4, mínimo 10 horas por hoja
KNN	Promedia el objetivo de las k horas más parecidas	No supone ninguna forma para la relación	k = 401, pesos inversos a la distancia

Métricas de evaluación. Como solo el 11.9 % de las horas de prueba son positivas, la exactitud no sirve. Se usan:

- **AP** (precisión promedio), el área bajo la curva precisión-exhaustividad [4]. Es la métrica de selección; un modelo al azar obtiene la tasa base, 0.119.
- **AUC ROC**, la probabilidad de que una hora con carga reciba una calificación mayor que una sin carga.
- **Brier** y su mejora sobre pronosticar siempre la tasa de entrenamiento (**BSS**): miden la calidad de la probabilidad, que es lo que necesita el optimizador.
- **F1, precisión y exhaustividad** con un umbral elegido para maximizar F1 en las predicciones fuera de muestra de la validación cruzada, nunca en la prueba.
- **Tiempo de entrenamiento y de predicción**, porque el modelo debe correr en un dispositivo Edge.

6. Comparación y selección de modelos

Se eligió la **regresión logística**: tiene la mejor AP en validación cruzada (el criterio que se fijó antes de ver la prueba), un Brier ligeramente menor en prueba (0.0872, aunque la diferencia con otros modelos es pequeña) y cuesta milisegundos. En la prueba, los seis modelos quedan muy cerca y sus intervalos al 95 % se traslapan.

Tabla 4. Resultados en el periodo de prueba (3,360 horas; tasa base 0.119).

Modelo	AP valid.	AP prueba [IC 95 %]	AUC prueba [IC 95 %]	Brier (BSS)	F1 / exhaust. (umbral)	Entrenar / predecir
Regresión logística	0.281	0.377 [0.303, 0.468]	0.852 [0.824, 0.877]	0.0872 (0.180)	0.450 / 0.763 (0.13)	35 ms / 7 ms
Random Forest	0.275	0.374 [0.302, 0.464]	0.852 [0.824, 0.876]	0.0889 (0.163)	0.410 / 0.486 (0.19)	674 ms / 86 ms

Modelo	AP valid.	AP prueba [IC 95 %]	AUC prueba [IC 95 %]	Brier (BSS)	F1 / exhaust. (umbral)	Entrenar / predecir
Bayes por hora y día	0.255	0.361 [0.292, 0.440]	0.860 [0.837, 0.882]	0.0877 (0.175)	0.465 / 0.746 (0.13)	2 ms / 1 ms
Naive Bayes	0.254	0.361 [0.296, 0.446]	0.848 [0.821, 0.874]	0.1022 (0.039)	0.459 / 0.783 (0.21)	12 ms / 5 ms
KNN	0.240	0.383 [0.320, 0.460]	0.857 [0.832, 0.879]	0.0879 (0.173)	0.454 / 0.850 (0.12)	17 ms / 556 ms
Árbol de decisión	0.238	0.330 [0.269, 0.397]	0.838 [0.815, 0.861]	0.0892 (0.161)	0.423 / 0.626 (0.16)	7 ms / 1 ms

Los intervalos salen de 1,000 remuestreos por bootstrap de días completos. BSS = 1 − Brier / 0.1063, donde 0.1063 es el Brier de pronosticar siempre la tasa de entrenamiento. Los tiempos se midieron en un servidor Linux para las 3,360 horas de prueba, no en una Raspberry Pi, y cambian de un equipo a otro.

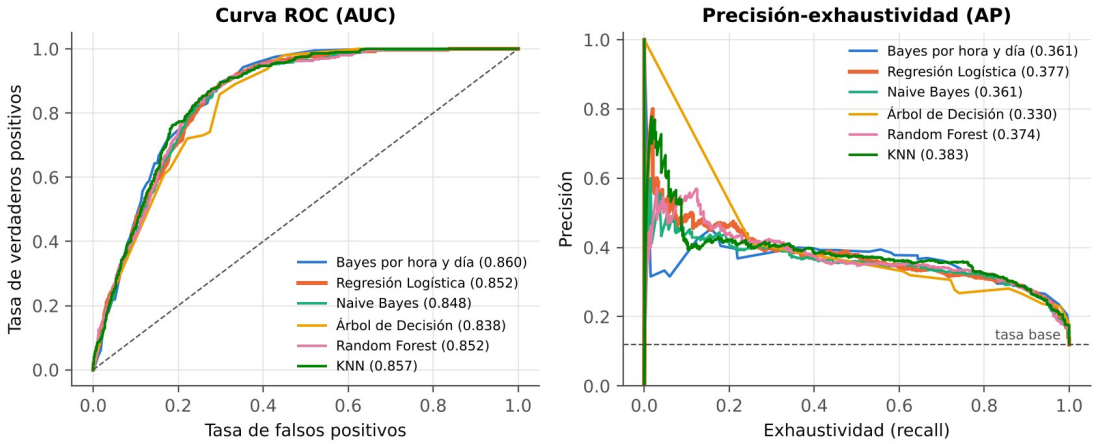


Figura 2. Curvas ROC y de precisión-exhaustividad en prueba. Entre paréntesis, AUC y AP.

Desempeño. Todos ordenan bien las horas (AUC de 0.838 a 0.860) y multiplican por 2.8 a 3.2 la AP del azar. Solo el árbol queda algo abajo; entre los demás, la prueba no permite separarlos. La ventaja de la regresión logística en validación sobre Random Forest es pequeña (0.281 contra 0.275), por lo que su elección se apoya también en simplicidad, interpretabilidad y costo.

Interpretabilidad. El modelo Beta-Binomial y la regresión logística se explican con una tabla de probabilidades o de razones de momios; Random Forest y KNN no.

Robustez. La regresión logística también gana en validación, que cubre cuatro periodos distintos del año. Naive Bayes y el Beta-Binomial casi no dependen de sus hiperparámetros.

Complejidad y tiempo. Random Forest tarda 19 veces más que la logística en entrenar. KNN tiene que guardar las 8,184 horas de entrenamiento y es el más lento al predecir (556 ms), lo que pesa en una Raspberry Pi.

Comportamiento con estos datos. Naive Bayes sobrestima: su probabilidad media en prueba es 0.170 contra una tasa real de 0.119, y por eso su BSS es apenas 0.039. Los otros cinco subestiman (media de 0.085 a 0.089) porque el EV cargó más en el invierno de prueba que en el año de entrenamiento.

Modelo final: regresión logística. Respaldo: el modelo Bayes por hora y día, que tiene el AUC más alto, tarda 2 ms y se puede actualizar en el dispositivo con solo sumar las cargas de cada día.

7. Desarrollo matemático y fundamentos teóricos

Se desarrollan la regresión logística (modelo final), Naive Bayes y el modelo Beta-Binomial, que es la base de la inferencia bayesiana del proyecto [5][6][7].

7.1 Regresión logística

Formulación. Para un vector de variables x, la probabilidad de carga es la función sigmoide de una combinación lineal; equivale a que el logaritmo de los momios sea lineal:

$$P(y=1 \mid \mathbf{x}) = \sigma(\mathbf{w}^T\mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T\mathbf{x} + b)}} \tag{1}$$

$$\log \frac{p}{1-p} = b + \sum_j w_j x_j \tag{2}$$

Función de costo. Se minimiza la log-verosimilitud negativa (entropía cruzada) con regularización L2, en la forma que usa scikit-learn [8] (el intercepto no se penaliza):

$$J(\mathbf{w}, b) = \tfrac{1}{2}\|\mathbf{w}\|^2 - C\sum_{i=1}^{n}[y_i \log p_i + (1-y_i)\log(1-p_i)] \tag{3}$$

Algoritmo de optimización. El gradiente y la matriz hessiana son:

$$\nabla_{\mathbf{w}} J = \mathbf{w} + C\sum_{i=1}^{n}(p_i - y_i)\mathbf{x}_i, \qquad \frac{\partial J}{\partial b} = C\sum_{i=1}^{n}(p_i - y_i) \tag{4}$$

$$\mathbf{H}_{\mathbf{w}} = \mathbf{I} + C\,\mathbf{X}^T\mathbf{S}\,\mathbf{X}, \qquad \mathbf{S} = \operatorname{diag}(p_i(1-p_i)) \tag{5}$$

Como H es definida positiva, J es estrictamente convexa y tiene un solo mínimo. No hay solución cerrada, así que se usa L-BFGS [9], un método cuasi-Newton que aproxima la inversa de la hessiana con los últimos gradientes. El descenso por gradiente, $w \leftarrow w - \eta\nabla J$, llega al mismo punto pero en más iteraciones. Con C = 10 la regularización es débil.

Supuestos. (1) El logaritmo de los momios es lineal en las variables: por eso la hora entra como 24 indicadoras, cada una con su parámetro. (2) Las observaciones son independientes: no se cumple del todo, porque las horas consecutivas están correlacionadas; afecta la incertidumbre de los coeficientes, no la predicción. (3) No hay colinealidad perfecta: las indicadoras completas más el intercepto sí la tienen, y la penalización L2 hace que la solución sea única.

Interpretación de los parámetros. $\exp(w_j)$ es la razón de momios: cuánto se multiplican los momios de carga al subir x_j en una unidad, con lo demás fijo. Como se conservan todas las categorías, se interpretan cocientes entre ellas:

Tabla 5. Razones de momios de la regresión logística.

Variable	Razón de momios	Lectura
Domingo contra lunes	1.253 / 0.304 = 4.1	Los momios de carga del domingo son 4.1 veces los del lunes
13:00 h contra 03:00 h	15.03 / 0.051 ≈ 294	La hora domina el modelo
`carga_ayer_hora`	1.35	Haber cargado ayer a esa hora sube los momios 35 %

Variable	Razón de momios	Lectura
ev_ayer_kwh (por 3.28 kWh, 1 desv. est.)	0.864	Más energía ayer, momios 13.6 % menores (posible explicación: batería más llena)
dias_sin_cargar (por 1.46 días)	0.902	Muchos días sin cargar podrían indicar que el auto no está en casa (hipótesis)
carga_semana_hora	0.798	Por sí sola sube la probabilidad (20.6 % contra 7.3 %), pero con la hora y frec_hora_28d en el modelo su información ya está incluida

7.2 Naive Bayes categórico

Formulación. Por el teorema de Bayes y el supuesto de independencia condicional de las d variables dada la clase:

$$P(y=c \mid \mathbf{x}) = \frac{P(y=c)\prod_{j=1}^{d} P(x_j \mid y=c)}{\sum_{c'} P(y=c')\prod_{j=1}^{d} P(x_j \mid y=c')} \tag{6}$$

$$\hat{y} = \operatorname{argmax}_c \left[\log P(y=c) + \sum_{j=1}^{d} \log P(x_j \mid y=c) \right] \tag{7}$$

La regla de decisión usa logaritmos para no multiplicar muchas probabilidades pequeñas, que darían desbordamiento numérico.

Función de costo y optimización. Se maximiza la log-verosimilitud conjunta, que tiene solución cerrada: entrenar es contar. Con suavizado de Laplace (α) para no asignar probabilidad cero a una categoría no vista:

$$\hat{P}(x_j = v \mid y=c) = \frac{N_{jvc} + \alpha}{N_c + \alpha K_j} \tag{8}$$

donde N_{jvc} es el número de horas de clase c con $x_j = v$, N_c el total de la clase y K_j el número de categorías de x_j. En términos bayesianos, este estimador es la media a posteriori con un prior Dirichlet(α, …, α) [5]. Con α = 0.0001 queda prácticamente el estimador de máxima verosimilitud.

Supuesto e interpretación. La independencia condicional no se cumple aquí: frec_hora_28d y carga_ayer_hora se calculan con la historia de la misma hora, así que repiten información de hora. Naive Bayes cuenta esa evidencia varias veces y empuja las probabilidades hacia los extremos. Eso explica su peor Brier (0.102) y su probabilidad media de 0.170 contra una tasa real de 0.119, aunque ordena bien las horas (AUC 0.848): la independencia falsa daña la calibración más que el orden.

7.3 Modelo Beta-Binomial (inferencia bayesiana)

Formulación. Para una hora fija, cada día es un ensayo de Bernoulli con probabilidad de carga θ. Con un prior Beta(a, b), la posterior también es Beta (conjugación): si hubo k cargas en n días,

$$p(\theta \mid k, n) \propto \theta^{k}(1-\theta)^{n-k}\,\theta^{a-1}(1-\theta)^{b-1} \tag{9}$$

$$\theta \mid k, n \;\sim\; \mathrm{Beta}(a+k,\; b+n-k) \tag{10}$$

Interpretación del parámetro. La media a posteriori es un promedio ponderado entre la media del prior y la frecuencia observada (encogimiento):

$$E[\theta \mid k, n] = \frac{a+k}{a+b+n} = \lambda \frac{a}{a+b} + (1-\lambda)\frac{k}{n}, \qquad \lambda = \frac{a+b}{a+b+n} \tag{11}$$

En el modelo “Bayes por hora y día”, a = s·p_0 y b = s·(1 − p_0), con p_0 = 0.0844 (tasa de entrenamiento) y s = 0.05. Cada celda hora × día tiene unos 49 días, así que λ ≈ 0.001 y mandan los datos; por eso la AP casi no cambia con s. No hay que optimizar nada: se entrena contando y se actualiza con cada día nuevo.

Inferencia. Con prior uniforme Beta(1, 1), separando laborables y fines de semana (Figura 3): a las 13:00 h, en fin de semana el EV cargó 39 de 96 días (θ ~ Beta(40, 58), media 0.408, intervalo de credibilidad al 95 % de [0.313, 0.507]); en días laborables cargó 65 de 245 (θ ~ Beta(66, 181), media 0.267, intervalo [0.214, 0.324]). Con 200,000 simulaciones de ambas posteriores, $P(\theta_{\text{fin de semana}} > \theta_{\text{laborable}} \mid \text{datos}) = 0.994$, con diferencia media de 0.141 e intervalo de credibilidad [0.030, 0.253].

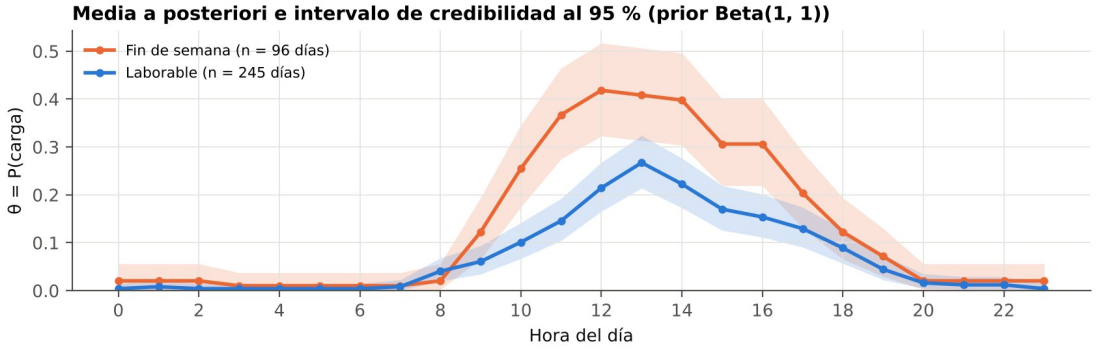


Figura 3. Probabilidad de carga por hora con prior Beta(1, 1): media a posteriori (línea) e intervalo de credibilidad al 95 % (banda).

7.4 Interpretación matemática de las métricas

$$\text{AUC} = P(s(\mathbf{x}^+) > s(\mathbf{x}^-)), \qquad \text{AP} = \sum_k (R_k - R_{k-1}) P_k \tag{12}$$

$$\text{Brier} = \frac{1}{n}\sum_{i=1}^{n}(p_i - y_i)^2, \qquad \text{BSS} = 1 - \frac{\text{Brier}}{\text{Brier}_{ref}}, \qquad F_1 = \frac{2PR}{P+R} \tag{13}$$

Un AUC de 0.852 significa que, en el 85.2 % de los pares formados por una hora con carga y una sin carga, el modelo califica más alto a la hora con carga (es el estadístico U de Mann-Whitney normalizado). La AP pondera la precisión P_k por cada aumento de exhaustividad R_k. El Brier es el error cuadrático de la probabilidad: un BSS de 0.180 indica que el error es 18 % menor que el de pronosticar siempre la tasa base [10].

8. Resultados y discusión

El modelo aprende bien el hábito de carga de la casa: a qué horas y qué días suele cargar. Lo que no puede saber es qué día concreto se va a conectar el auto.

Interpretación de métricas (regresión logística, prueba). AUC de 0.852 y AP de 0.377, 3.2 veces la tasa base de 0.119. Con el umbral de 0.13 detecta el 76.3 % de las horas con carga (exhaustividad), pero solo el 31.9 % de las horas que señala son de carga real (precisión); F1 = 0.450. Sus probabilidades tienen 18 % menos error

cuadrático que la tasa constante (BSS 0.180). Para el orquestador importa más la probabilidad que la clase: le dice cuánto confía en que el auto cargue a cada hora.

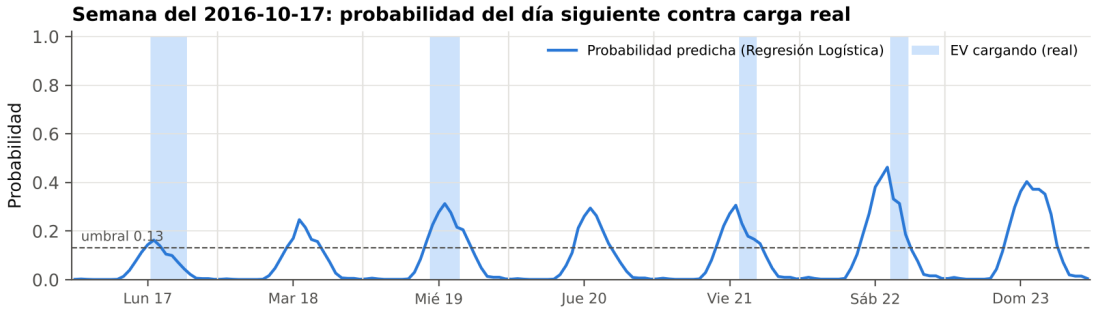


Figura 4. Primera semana completa del periodo de prueba: probabilidad del día siguiente (línea) y horas con el EV cargando (barras).

Fortalezas. Reproduce la forma diaria de la carga, con picos al mediodía más altos en fin de semana. Es ligero (35 ms para entrenar con un año de datos) y sus coeficientes se pueden explicar.

Limitaciones. La hora domina: si se desordena la variable `hora`, la AP en prueba cae 0.232; con `ev_ayer_kwh` cae 0.024, con `dia_semana` 0.021 y con las demás 0.006 o menos. Por eso, en la Figura 4 el modelo da probabilidades de 0.2 a 0.3 al mediodía del martes y del jueves, días en que el auto no cargó. Para anticipar días concretos harían falta datos que no tenemos: estado de carga de la batería, viajes, agenda o pronóstico solar.

Posibles fuentes de error o sesgo.

- *Cambio de nivel:* la tasa de carga sube de 8.4 % en entrenamiento a 11.9 % en prueba, así que el modelo subestima (probabilidad media de 0.089).
- *Una sola vivienda alemana:* los resultados no se generalizan a otros hogares.
- *Objetivo:* “está cargando” no es lo mismo que “está conectado y disponible”, que es lo que necesita el optimizador; OPSD no registra cuándo se conecta el auto.
- *Calibración no evaluada a fondo:* solo se comparó la probabilidad media con la tasa real y el Brier; no se construyó una curva de confiabilidad.
- *Dependencia temporal:* las horas no son independientes, lo que viola un supuesto de los modelos y hace que la incertidumbre de los coeficientes se subestime.
- *Periodo de prueba:* solo cubre otoño e invierno, y el umbral de F1 da el mismo peso a falsos positivos y falsos negativos.

Reflexión sobre los modelos. La señal es casi aditiva en hora y día, por eso un modelo lineal con indicadoras basta y los árboles no ganan: un árbol de profundidad 4 no puede representar bien 24 horas, y Random Forest reduce la varianza sin mejorar la AP. KNN ordena bien pero es caro de usar. Naive Bayes pierde calibración por la dependencia entre variables. El modelo Beta-Binomial, que solo cuenta cargas por hora y día, queda casi igual que los demás: la mayor parte de la señal es el hábito.

Implicación para el orquestador (notebook 04). El optimizador del proyecto supone que el auto se carga de 18:00 a 08:00 h, pero solo el 7.2 % de la energía del EV se carga en ese horario (4.4 % en los días de prueba). Para ver qué cambia si la ventana sale del hábito, la Parte 2 del notebook 04 define ventanas con la probabilidad de carga por hora estimada con el año de entrenamiento (media a posteriori Beta-Binomial, la versión por hora del modelo de respaldo) y las evalúa en los 83 días de prueba con EV (14 oct 2016 – 5 mar 2017). Una ventana aprendida con umbral τ incluye las horas con $P(\text{carga} \mid \text{hora}) \geq \tau$. En cada día, un programa lineal reparte la energía real del día en las horas de la ventana (3.2 kW como máximo) y se compara con el costo observado, que fue de 4.146 MXN por día en promedio.

Tabla 6. Ahorro simulado del EV por tipo de ventana (días de prueba, PML del SIN).

Ventana	Horas	Energía real dentro de la ventana	Ahorro medio (MXN/día)	Ahorro (% del costo del EV)
Noche 18:00–08:00 (supuesto fijo)	14	4.4 %	2.22	53.5 %
Aprendida, τ = 0.02 (08:00–20:00)	12	98.3 %	2.25	54.2 %
Aprendida, τ = 0.05 (09:00–19:00)	10	96.8 %	2.23	53.8 %
Aprendida, τ = 0.10 (10:00–18:00)	8	93.6 %	2.14	51.5 %
Libre, 24 h	24	100 %	2.25	54.3 %

Lectura. El ahorro simulado casi no depende de la ventana: va de 51.5 % a 54.3 % del costo del EV, y la ventana nocturna (53.5 %) queda prácticamente igual que las aprendidas; ninguna ventana dejó días sin poder repartirse. La razón está en el perfil de PML: la hora más barata es las 10:00 h (347.46 MXN/MWh) y las 9:00 y 11:00 h cuestan 359.09 y 355.21, casi lo mismo que la madrugada, mientras que el EV observado carga sobre todo alrededor de las 13:00 h, cuando el PML sube a entre 752.89 y 1,065.90 MXN/MWh. Con una ventana aprendida el optimizador no necesita suponer que el auto se carga de noche: logra el mismo ahorro adelantando la carga unas horas dentro de su horario habitual, y la cobertura (94 a 98 % de la energía real dentro de la ventana, contra 4.4 % de la nocturna) hace ese supuesto más creíble.

Qué tomar con cuidado. (1) El PML es el de un solo día aplicado a todos los días, así que las horas baratas de la mañana pueden no repetirse en otras fechas. (2) El programa lineal supone que el auto está conectado y puede cargar a 3.2 kW en cualquier hora de la ventana; las ventanas aprendidas describen cuándo el auto *estaba cargando*, no cuándo estaba conectado, y adelantar la carga solo es posible si ya estaba enchufado. (3) El ahorro es sobre el costo del EV a precio mayorista, no sobre una factura. (4) Es una simulación con 83 días de una sola vivienda y sin intervalos de confianza.

9. Conclusiones y trabajo futuro

9.1 Principales hallazgos

- Con información del día anterior se puede predecir en qué horas carga el EV con AUC de 0.84 a 0.86 y AP de hasta 3.2 veces la del azar.
- La regresión logística es el mejor balance: la mejor AP en validación (0.281), un Brier ligeramente menor (0.0872) y un costo de milisegundos.
- Casi toda la señal es el hábito por hora y día: el modelo Beta-Binomial, que solo cuenta cargas, queda a la par de los modelos complejos y tiene el AUC más alto (0.860).
- La inferencia bayesiana indica que la carga del mediodía es más probable en fin de semana: a las 13:00 h, $P(\theta_{\text{fin de semana}} > \theta_{\text{laborable}} \mid \text{datos}) = 0.994$.

- El 83 % de la energía del EV se carga entre las 10:00 y las 17:00 h, lo que contradice la ventana nocturna que supone el optimizador. Con una ventana aprendida del hábito, el ahorro simulado en los días de prueba (alrededor de 54 % del costo del EV, 2.2 MXN por día) es prácticamente el mismo que con la ventana de 18:00 a 08:00 h.

9.2 Limitaciones

Una sola vivienda, de Alemania; un cambio de nivel entre entrenamiento y prueba; un objetivo que mide carga y no disponibilidad del auto; calibración no evaluada con curva de confiabilidad; y dependencia temporal entre horas.

9.3 Mejoras y líneas de trabajo posteriores

- Recalibrar las probabilidades con datos recientes (regresión isotónica o un prior Beta que se actualice día a día) para corregir el cambio de nivel, y evaluar la calibración con una curva de confiabilidad.
- Agregar la generación solar medida (pv de OPSD, ya disponible en la base de datos) para comprobar si la carga de mediodía la sigue, además de clima o pronóstico solar y, si hubiera hardware, el estado de carga de la batería.
- Validar con varias viviendas y con datos de México.
- Usar la probabilidad por día de la regresión logística (no solo por hora) para definir la ventana de cada día, obtener datos de cuándo está conectado el auto y llevar el modelo Beta-Binomial al dispositivo Edge como versión que se actualiza en línea.

10. Referencias

[1] Open Power System Data. (2020). *Data package household data* (Versión 2020-04-15) [Conjunto de datos]. https://data.open-power-system-data.org/household_data/2020-04-15/

[2] Centro Nacional de Control de Energía. (2026). *Precios marginales locales MDA: Promedios horarios ($/MWh)* [Conjunto de datos]. Sistema de Información del Mercado. https://www.cenace.gob.mx/

[3] Wiese, F., Schlecht, I., Bunke, W.-D., Gerbaulet, C., Hirth, L., Jahn, M., Kunz, F., Lorenz, C., Mühlenpfordt, J., Reimann, J., & Schill, W.-P. (2019). Open Power System Data – Frictionless data for electricity system modelling. *Applied Energy*, *236*, 401–409. https://doi.org/10.1016/j.apenergy.2018.11.097

[4] Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, *10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432

[5] Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian data analysis* (3.ª ed.). CRC Press.

[6] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning* (2.ª ed.). Springer.

[7] Murphy, K. P. (2012). *Machine learning: A probabilistic perspective*. MIT Press.

[8] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

[9] Liu, D. C., & Nocedal, J. (1989). On the limited memory BFGS method for large scale optimization. *Mathematical Programming*, *45*(1–3), 503–528. https://doi.org/10.1007/BF01589116

[10] Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, *78*(1), 1–3.

[11] McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

[12] Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, *9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

[13] NumPy Developers. (s. f.). *NumPy documentation*. https://numpy.org/doc/

[14] SciPy Developers. (s. f.). *SciPy documentation*. https://docs.scipy.org/doc/scipy/

Código entregado y uso de IA

Código. Se entregan tres notebooks de Jupyter: `00_ingesta_limpieza.ipynb`, que lee el CSV de OPSD y genera `datos_horarios.csv`; `02_ml_clasificacion_ev.ipynb`, con la preparación de variables, el análisis exploratorio, los seis modelos, la comparación y la inferencia bayesiana. Este genera `resultados_ml.json`, con las cifras de este reporte, y las figuras; y `04_optimizador_lp.ipynb`, que simula el optimizador lineal y compara la ventana nocturna con ventanas aprendidas del hábito (sección 8) y genera `resultados_optimizador.json`. Requiere Python 3 con pandas [11], NumPy [13], SciPy [14], scikit-learn [8] y Matplotlib [12], y tarda alrededor de un minuto. Las cifras se repiten con la semilla 42, salvo los tiempos, que dependen del equipo. Repositorio: https://github.com/22Freetwo/PowerShift-AI-Orquestador-Energia.

Uso de IA. Los lineamientos permiten usar IA generativa como apoyo. El equipo usó Gemini (Google) y Claude (Anthropic) como asistentes para estructurar y dar formato a los textos, validar valores y fórmulas, recibir consejos para resolver errores de código y orientarse sobre qué modelos, métricas y decisiones convenía tomar. Las decisiones metodológicas, el código y las cifras de este reporte fueron revisados y comprobados por el equipo: se ejecutaron los notebooks, se contrastaron los resultados con los valores obtenidos y con otros valores válidos para decidir si una opción valía la pena y funcionaba correctamente, y se corrigieron detalles que la IA omitió. El equipo es responsable del contenido que aquí se entrega.