PowerShift AI: Orquestador Invisible de Energía y Costos
Inferencia estadística y evaluación de riesgo para la optimización energética residencial en hardware Edge

Gabriel Orozco Alvárez,[1] Yohann Emmanuel Bustos Peñaloza,[1]
Angel Zoe García Granados,[1] and Juan Pablo Arroyo León[1]

[1] *Licenciatura en Inteligencia Artificial y Ciencia de Datos, Centro Universitario de Guadalajara (CUGDL), Universidad de Guadalajara*
Probabilidad y Estadística II 2026A — Profesor: Dr. Hugo Adrian Ortega Rosales

(Dated: Noviembre de 2026)

PowerShift AI es un orquestador que opera en hardware Edge (Raspberry Pi) y reprograma cargas pesadas del hogar hacia las horas de menor Precio Marginal Local (PML). Este trabajo contrasta con tres pruebas de hipótesis los supuestos que respaldan al sistema, usando telemetría real de una vivienda (Open Power System Data) y el perfil horario de PML del SIN (CENACE). Una prueba t pareada indica que el ahorro diario esperado en el costo de las cargas controlables es distinto de cero ($\bar{D} = 2{,}09$ MXN, $p = 4{,}1 \times 10^{-9}$); un ANOVA de un factor no encuentra diferencias significativas en la potencia de la bomba de calor entre franjas horarias ($p = 0{,}445$); y una prueba de bondad de ajuste χ^2 rechaza la normalidad de la carga nocturna ($p = 0{,}0058$). Las PDF de t, F y χ^2 se programaron a mano y sus colas se integraron con `scipy.integrate.quad`, sin usar `scipy.stats`. El escenario con orquestador es una simulación, por lo que el ahorro es esperado y no medido en campo. Se incluye el análisis de errores Tipo I y II.

I. INTRODUCCIÓN

Los precios marginales locales (PML) del mercado eléctrico mexicano cambian hora a hora [4], y una parte importante del consumo residencial se concentra en pocas cargas de alta potencia, como la climatización y la carga de vehículos eléctricos (EV) [3]. Desplazar esas cargas hacia horas baratas reduce el recibo sin que el usuario intervenga.

PowerShift AI toma la telemetría de consumo, la cruza por hora con el PML y resuelve un problema de programación lineal que decide cuándo operar cada equipo. Antes de confiar en esas decisiones en un dispositivo Edge conviene respaldar con inferencia formal tres supuestos [1]: que el sistema reduce el costo, que el consumo de la climatización depende de la franja horaria y que la carga base nocturna es aproximadamente Normal, lo que permitiría usar métodos gaussianos de bajo costo.

II. PLANTEAMIENTO DEL PROBLEMA E HIPÓTESIS

Todas las pruebas usan $\alpha = 0{,}05$.

Prueba 1 (observaciones pareadas). Para $n = 30$ días de una misma vivienda se compara el costo diario de las cargas controlables (EV y bomba de calor) sin orquestador (X_{1i}) contra el costo con PowerShift AI (X_{2i}); $D_i = X_{1i} - X_{2i}$.

- H_0: el costo medio diario de las cargas controlables sin el orquestador es igual al costo medio con PowerShift AI; el sistema no genera ahorro ($\mu_D = 0$).
- H_1: el costo medio diario sin el orquestador es mayor que con PowerShift AI; el sistema sí reduce el costo ($\mu_D > 0$).

Prueba 2 (ANOVA de un factor). Se compara la potencia media de la bomba de calor en tres franjas horarias: madrugada (00–08 h), día (08–16 h) y noche (16–24 h), usando los meses de calefacción (diciembre a febrero).

- H_0: el consumo promedio de la bomba de calor es el mismo en las tres franjas horarias.
- H_1: en al menos una franja horaria el consumo promedio de la bomba de calor es distinto al de las demás.

Prueba 3 (bondad de ajuste χ^2). Se evalúa la potencia que la vivienda toma de la red entre 01:00 y 05:00 h.

- H_0: el consumo eléctrico nocturno de la vivienda sigue una distribución Normal.
- H_1: el consumo eléctrico nocturno de la vivienda no sigue una distribución Normal.

Se aplica a la carga nocturna porque es la señal base sobre la que un método gaussiano estimaría intervalos de confianza en el Edge antes de decidir un encendido.

III. METODOLOGÍA

A. Datos y construcción de las muestras

Consumo. Se usó el conjunto *Household Data* de Open Power System Data [3] (viviendas de Konstanz, Alemania; lecturas cada 15 min). Se eligió la vivienda `DE_KN_residential4`, la única con bomba de calor, EV y consumo de red medidos a la vez. Las columnas son

lecturas *acumuladas* de medidor (kWh); se diferenciaron para obtener la energía de cada intervalo y se multiplicó por 4 para pasar a kW. Se convirtió a hora local, se interpolaron huecos de hasta 1 h, se descartaron cinco días (tres por cambio de horario y dos parciales en los extremos de la ventana) y se promedió por hora. Quedaron 506 días completos (octubre de 2015 a marzo de 2017).

Precio. Se usó el PML MDA promedio horario del sistema SIN publicado por CENACE [4]: un perfil de 24 valores, aplicado a todos los días, con máximo de 2,210.92 MXN/MWh a las 19 h. El costo de una carga es

$$\text{costo} = \frac{\text{kW} \times h \times \text{PML}}{1000}, \tag{1}$$

pues el PML está en MXN/MWh.

Escenario con orquestador (simulado). No hay hardware instalado, por lo que el escenario "con PowerShift AI" es una **simulación**: para cada día con carga de EV ($\geq$ 0,5 kWh; 268 de 506 días), un programa lineal reparte la energía del día en las horas permitidas (18:00 a 08:00, potencia máxima de 3.2 kW) minimizando el costo. La bomba de calor no se mueve, como restricción de confort; el ahorro proviene del EV. La ventana de 18:00 a 08:00 h es un supuesto de diseño: en los datos solo el 7,2 % de la energía del EV se carga en ese horario. Como verificación, con ventanas aprendidas del hábito de carga (83 días de prueba) el ahorro simulado fue prácticamente el mismo: 53,8 % del costo del EV, contra 53,5 % con la ventana nocturna.

Muestras. Con semilla fija (42), fijada antes de ver resultados: 30 días al azar entre los 268 con carga de EV (prueba 1); 10 lecturas horarias de la bomba de calor al azar por franja en diciembre a febrero (prueba 2); y 20 lecturas horarias de `grid_import` entre 01 y 05 h (prueba 3).

Limitaciones. (i) El ahorro es simulado, no medido. (ii) Los datos de consumo son de Alemania y el PML es de México: las cifras en pesos ilustran el método y no predicen una factura. (iii) El PML es un perfil típico de un día, por lo que el costo varía entre días solo por el consumo. (iv) El costo se calcula sobre EV y bomba de calor, no sobre la factura total. (v) Las lecturas de una serie de tiempo pueden estar autocorrelacionadas y aquí se tratan como independientes. (vi) La bomba de calor de esta vivienda es de calefacción, no de aire acondicionado.

B. Desarrollo matemático

Siguiendo las reglas del curso, las funciones de densidad se programaron a mano y el valor p se obtiene integrando numéricamente la cola de cada PDF con `scipy.integrate.quad`, *sin* emplear `scipy.stats`. La función Γ se evalúa con `scipy.special.gamma`, y los valores críticos se obtienen por barrido sobre una malla `np.linspace`, integrando la PDF hasta alcanzar la probabilidad acumulada deseada, como se hizo en clase.

t pareada. Con $\bar{D}$ y S_D la media y desviación estándar de las D_i y $\nu = n - 1$,

$$t_0 = \frac{\bar{D}}{S_D/\sqrt{n}}, \quad g(t;\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{t^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \tag{2}$$

$$p = P(T \geq t_0) = \int_{t_0}^{\infty} g(t; n-1)\, dt. \tag{3}$$

ANOVA. Con $SST_R = \sum_i n_i(\bar{X}_{i\cdot} - \bar{X}_{\cdot\cdot})^2$ y $SSE = \sum_i \sum_j (X_{ij} - \bar{X}_{i\cdot})^2$,

$$F_0 = \frac{SST_R/(k-1)}{SSE/(N-k)}, \quad p = \int_{F_0}^{\infty} g(f; \nu_1, \nu_2)\, df, \tag{4}$$

con g la densidad F de Fisher, $\nu_1 = k - 1$ y $\nu_2 = N - k$:

$$g(f;\nu_1,\nu_2) = \frac{\Gamma\left(\frac{\nu_1+\nu_2}{2}\right)}{\Gamma\left(\frac{\nu_1}{2}\right)\Gamma\left(\frac{\nu_2}{2}\right)} \left(\frac{\nu_1}{\nu_2}\right)^{\frac{\nu_1}{2}} \frac{f^{\frac{\nu_1}{2}-1}}{\left(1 + \frac{\nu_1}{\nu_2} f\right)^{\frac{\nu_1+\nu_2}{2}}}. \tag{5}$$

Bondad de ajuste χ^2. Con k clases equiprobables bajo la Normal ajustada ($E_i = n/k$) y $m = 2$ parámetros estimados $(\hat{\mu}, \hat{\sigma})$, $\nu = k - 1 - m$:

$$\chi_0^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}, \quad p = \int_{\chi_0^2}^{\infty} \frac{x^{\frac{\nu}{2}-1} e^{-x/2}}{2^{\nu/2}\Gamma\left(\frac{\nu}{2}\right)}\, dx. \tag{6}$$

Los cortes de las clases usan cuantiles de la Normal estándar obtenidos con el mismo barrido numérico.

IV. RESULTADOS

A. Prueba 1: ahorro de costo pareado

Con $n = 30$ días, el costo medio diario fue $\bar{X}_1 =$ \$10,65 MXN sin orquestador y $\bar{X}_2 =$ \$8,56 MXN con PowerShift AI, es decir, $\bar{D} =$ \$2,09 ($\approx$ 19,6 %) con $S_D =$ \$1,43. El error estándar es 0,262, de modo que $t_0 = 7{,}99$ con $\nu = 29$, $t_{crit} = 1{,}700$ y $p = 4{,}1 \times 10^{-9} < 0{,}05$. Se rechaza H_0 (figura 1). Un intervalo de confianza al 95 % para μ_D es [1,56, 2,63] MXN por día. La prueba de normalidad de las D_i con la misma función χ^2 no rechaza ($\chi_0^2 = 1{,}2$, $p = 0{,}273$), lo que respalda el uso de la t. En términos del costo del EV solamente, el ahorro simulado es de 54 % (el optimizador concentra la carga entre las 02 y las 06 h). Como el escenario con orquestador es simulado, la conclusión es que el *ahorro esperado* es estadísticamente distinto de cero, no que se haya medido en una vivienda real.

B. Prueba 2: ANOVA de la bomba de calor

Las medias de potencia fueron 0,856 kW (madrugada), 0,692 kW (día) y 0,693 kW (noche), con desviaciones estándar de 0,476, 0,218 y 0,213 kW. El cuadro I resume

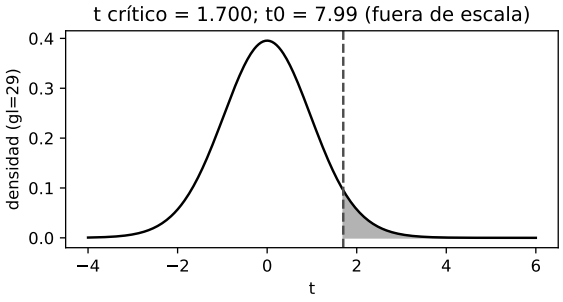


Figura 1. Densidad t con $\nu = 29$. La región sombreada es la zona de rechazo de H_0 ($\alpha = 0{,}05$, cola derecha); el estadístico observado $t_0 = 7{,}99$ cae dentro de ella.

el análisis: $F_0 = 0{,}834$ con $(2, 27)$ grados de libertad, $F_{crit} = 3{,}354$ y $p = 0{,}445 > 0{,}05$, por lo que **no se rechaza** H_0 (figura 2). Las comparaciones por pares con el MSE y corrección de Bonferroni tampoco son significativas ($p = 0{,}27$, $0{,}27$ y $0{,}99$). Hay que leer este resultado con cautela: con solo 10 lecturas por franja la prueba tiene poca potencia, y el cociente entre la mayor y la menor varianza muestral es 4,98 ($p \approx 0{,}026$, orientativo), por lo que el supuesto de varianzas iguales es dudoso. Los residuos sí son compatibles con la normalidad ($\chi^2_0 = 2{,}8$, $p = 0{,}094$).

Tabla I. ANOVA de un factor para la potencia de la bomba de calor.

Fuente	SS	gl	MS	F_0	p
Franjas	0.178	2	0.0888	0.834	0.445
Error	2.874	27	0.1064	—	—
Total	3.051	29	—	—	—

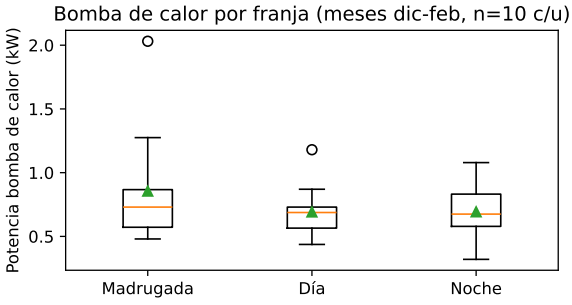


Figura 2. Potencia de la bomba de calor por franja horaria (diciembre a febrero, $n = 10$ por franja). El triángulo marca la media.

C. Prueba 3: bondad de ajuste χ^2

Para $n = 20$ lecturas nocturnas, $\hat{\mu} = 0{,}558$ kW y $\hat{\sigma} = 0{,}342$ kW. Con $k = 4$ clases equiprobables ($E_i = 5$) las frecuencias observadas fueron $(8, 0, 7, 5)$, $\chi^2_0 = 7{,}60$, $\nu = 1$, $\chi^2_{crit} = 3{,}842$ y $p = 0{,}0058 < 0{,}05$. Se rechaza H_0: hay evidencia de que la carga nocturna no es Normal (figura 3). Por lo tanto no conviene asumir normalidad en esa señal dentro del Edge; son preferibles métodos que no dependan de ella, como intervalos basados en cuantiles empíricos.

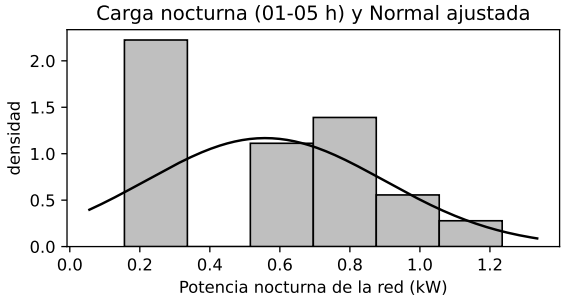


Figura 3. Histograma de la carga nocturna (01–05 h, $n = 20$) y densidad Normal ajustada.

V. DISCUSIÓN: ERRORES TIPO I Y II

El Edge decide automáticamente bajo incertidumbre, por lo que el cuadro II describe qué costaría cada error [2]. El nivel $\alpha = 0{,}05$ acepta un 5 % de probabilidad de declarar un efecto inexistente. En la prueba 1 el Error Tipo I es el más grave comercialmente, pues se desplegaría un algoritmo que no ahorra. En la prueba 2 el resultado no significativo es compatible con un Error Tipo II: con $n = 10$ por franja y varianzas desiguales, una diferencia real podría no detectarse, y el riesgo es tratar la bomba de calor como carga plana. En la prueba 3 el rechazo apunta a no usar intervalos gaussianos, con lo que se evita el riesgo del Tipo II (aceptar normalidad falsa y distorsionar los intervalos).

VI. CONCLUSIONES

El ahorro diario esperado del orquestador ($\approx$ \$2,09 MXN, 19.6 % del costo de EV y bomba de calor) es estadísticamente distinto de cero en simulación, con supuestos razonables para la prueba t. No se encontró evidencia de que la potencia de la bomba de calor difiera entre franjas horarias, aunque la potencia de la prueba es limitada, y la carga nocturna no sigue una Normal, por lo que el Edge no debe asumirla. El ahorro simulado no depende de la ventana nocturna, aunque todos los escenarios

Tabla II. Matriz de errores Tipo I y II y su riesgo operativo/financiero.

Prueba	**Error Tipo I (α) y riesgo**	**Error Tipo II (β) y riesgo**
1. Pareada (ahorro)	Concluir que el sistema ahorra cuando $\mu_D = 0$. Riesgo: desplegar software que no reduce el costo y generar descontento del cliente.	No detectar un ahorro real. Riesgo: descartar un algoritmo funcional y rentable.
2. ANOVA (bomba de calor por franja)	Concluir que el consumo difiere por franja cuando es homogéneo. Riesgo: reprogramar la climatización sin ganancia y afectar el confort.	No detectar diferencias reales entre franjas (probable aquí por el tamaño de muestra). Riesgo: tratar la carga como plana y perder oportunidades de ahorro.
3. χ^2 (normalidad nocturna)	Rechazar la normalidad cuando la carga sí es Normal. Riesgo: usar métodos no paramétricos menos potentes y más costosos en la Raspberry Pi.	Aceptar la normalidad cuando hay sesgo o colas pesadas. Riesgo: intervalos de confianza distorsionados y encendidos erróneos.

suponen que el auto está conectado. Los resultados provienen de una vivienda alemana y de un perfil de PML de un solo día, de modo que el siguiente paso es repetir el análisis con varios días de PML y con mediciones en hardware real. Las PDF se programaron a mano y sus colas se integraron numéricamente, conforme a los lineamientos de la materia.

[1] Devore, J. L. (2020). *Probabilidad y estadística para ingeniería y ciencias* (10.ª ed.). Cengage Learning.

[2] Montgomery, D. C., & Runger, G. C. (2018). *Applied statistics and probability for engineers* (7th ed.). Wiley.

[3] Open Power System Data. (2020). *Data package household data: Measured electricity consumption and generation of households and small businesses* (Versión 2020-04-15) [Conjunto de datos]. https://data.open-power-system-data.org/household_data/2020-04-15/

[4] Centro Nacional de Control de Energía. (2026). *Sistema de Información del Mercado (SIM): Precios Marginales Locales (PML)*. CENACE. https://www.cenace.gob.mx/